

Lastenheft

Speech and LLM Quality Lab

Fachliche Anforderungen an ein lokales Werkzeug zur Qualitätsprüfung französischer Sprachdaten und zur Evaluation von Speech to Text und LLM Antworten.

Merkmal	Festlegung
Dokumentstand	Version 1.0 · 18. September 2026
Projektverantwortung	Pascal Cabrel Nague
Projektart	Eigenständiges Lern und Portfolio Projekt
Arbeitsdomäne	Französischer Sprachassistent für fiktiven IT Support
Planungsstatus	Spezifikationsbasis zur Umsetzung; noch keine Abnahme
Verbindlichkeit	Projektinterne Festlegungen;

Zweck und Leseführung

Das Projekt verbindet französische Sprachdatenprüfung mit nachvollziehbarer Modellbewertung. Es soll zeigen, wie Fehler erfasst, Ursachen getrennt und Änderungen reproduzierbar geprüft werden. Die Spezifikation beschreibt geplante Funktionen und keine bereits implementierten Ergebnisse.

Inhaltsübersicht

- 1 Ausgangslage und Projektziele
- 2 Einsatzbereich und Nutzungsszenarien
- 3 Funktionale Anforderungen an Sprachdaten und ASR
- 4 Funktionale Anforderungen an LLM und Auswertung
- 5 Datenanforderungen und Qualitätsmerkmale
- 6 Rahmenbedingungen und Lieferumfang
- 7 Abnahme und Erfolgskriterien
- 8 Projektplanung und Risiken
- 9 Änderungsverfahren und Begriffe

1 Ausgangslage und Projektziele

1 1 Ausgangslage

Sprachassistenten können trotz flüssig formulierter Antworten falsche Ergebnisse liefern. Ursachen liegen unter anderem in fehlerhaften Audiodaten, unpassenden Transkriptionen, verlorenen Negationen, falschen Zahlen, unvollständiger Dokumentensuche oder unbelegten LLM Aussagen. Ein Gesamtscore allein reicht nicht aus, um diese Ursachen zu unterscheiden.

Die von Pascal bereitgestellte KENBUN Ausschreibung legt den Schwerpunkt auf französische Sprachdaten, Python Analysen und die systematische Untersuchung von Fehlermustern. Das Portfolio Projekt übernimmt diese fachlichen Schwerpunkte und erweitert sie um LLM Evaluation und Regressionstests. Es nutzt keine internen KENBUN Daten, Modelle oder Infrastruktur.

1 2 Zielbild

Ziel	Messbarer Nachweis
Z1 Sprachliche Qualität untersuchen	Mindestens 120 geprüfte Audio Text Paare mit Kategorien und dokumentierten Annotationsregeln.
Z2 ASR transparent vergleichen	Zwei eingefrorene ASR Konfigurationen auf identischen Daten; globale und kategorisierte Ergebnisse samt Fehlerbeispielen.
Z3 LLM Antworten bewerten	Mindestens 60 Textfälle mit erwarteten Aussagen, Belegen und Verhalten; zwei Promptvarianten eines Modells.
Z4 Fehlerweitergabe sichtbar machen	30 gesperrte End to End Fälle jeweils mit Referenztext und ASR Text; Retrieval und Antwort getrennt untersuchen.
Z5 Änderungen zuverlässig testen	Automatischer Vergleich mit Baseline sowie verständliche Kennzeichnung von Fehlern, Warnungen und unvollständigen Läufen.
Z6 Bewerbungsfähige Ergebnisse liefern	Ausführbare lokale Demo, nachvollziehbarer Bericht und dokumentierter Quellcode ohne erfundene Leistungsaussagen.

1 3 Erfolg und Abgrenzung

Erfolg bedeutet eine verlässliche Messung und verständliche Fehleranalyse. Ein schlechter Modellscore darf die Abnahme des Evaluationswerkzeugs nicht verhindern, sofern er korrekt berechnet und vollständig berichtet wird. Eine nachgewiesene Modellverbesserung ist ein Forschungsergebnis, keine Liefergarantie.

Nicht enthalten sind ein produktiver Kundensupport, medizinische Entscheidungen, Telefonie, eine mobile App, Sprachausgabe, Mehrmandantenbetrieb, ein öffentlicher Dienst und das Training eines

Grundmodells. Fine Tuning, zusätzliche Sprachen und mehrere Sprecher sind mögliche spätere Erweiterungen.

2 Einsatzbereich und Nutzungsszenarien

2 1 Beteiligte

Rolle	Aufgabe und Entscheidung
Projektverantwortlicher	Pascal priorisiert Anforderungen, entwickelt, annotiert und nimmt das Ergebnis projektintern ab.
Optionaler Reviewer	Prüft einen Teil der Annotationen und Bewertungen; Verfügbarkeit ist nicht Voraussetzung für die erste Version.
Demonstrationsnutzer	Betrachtet vorab erzeugte Ergebnisse und untersucht Fehler über das lokale Dashboard.
Externe Unternehmen	Mögliche Leser des Portfolios; keine zugesagte Betreuung und keine formale Auftraggeberrolle.

2 2 Hauptszenarien

Fall	Ablauf und Ergebnis
UC01 Daten prüfen	Nutzer importiert ein Manifest, sieht Fehler und korrigiert fehlende oder widersprüchliche Angaben. Nur valide Beispiele gelangen in den Benchmark.
UC02 Sprachmodell vergleichen	Nutzer wählt Datensatz und zwei Konfigurationen. Das System führt Transkriptionen aus und erzeugt vergleichbare Scores und Fehlerlisten.
UC03 Fehler untersuchen	Nutzer filtert nach Zahlen oder Negationen, hört das Original und dokumentiert eine begründete Fehlerkategorie.
UC04 LLM testen	Nutzer startet eine feste Testsuite gegen zwei Promptvarianten. Antworten werden regelbasiert und anhand einer menschlichen Rubrik bewertet.
UC05 Ursache eingrenzen	Nutzer vergleicht Antworten auf korrekte und erkannte Texte. Das System zeigt veränderte Suchtreffer und Antwortbewertungen nebeneinander.
UC06 Änderung bewerten	Nutzer vergleicht einen neuen Lauf mit einer kompatiblen Baseline und exportiert einen Bericht mit Regressionen.

2 3 Bedienung und Einsatzgrenzen

Die Hauptnutzung findet lokal durch eine Person statt. Batch Verarbeitung und Ergebnisauswertung müssen ohne dauerhaft laufenden Webserver möglich sein. Das Dashboard dient der Prüfung gespeicherter Ergebnisse, nicht dem autonomen Ausführen administrativer Aufgaben.

Französisch ist die Sprache der Audios, Fragen und Modellantworten. Die Projektdokumentation wird auf Deutsch geführt; Feldnamen und Schnittstellen

werden einheitlich auf Englisch benannt. Bereits vorhandene Werkzeuge und Modelle werden verwendet, ihre Auswahl ist im Pflichtenheft festgelegt beziehungsweise als Entscheidungstermin ausgewiesen.

3 Anforderungen an Sprachdaten und ASR

Prioritäten: MUSS gehört zur vollständigen Version 1. SOLL wird bei ausreichendem Zeitbudget umgesetzt und sonst ausdrücklich als offen dokumentiert. KANN gehört nicht zur Abnahme. F bezeichnet eine funktionale Anforderung; der Nachweis erfolgt über die Tests T01 bis T18 im Pflichtenheft.

ID	Prio	Anforderung und Akzeptanzbedingung
F01	MUSS	Manifest importieren und validieren. Fehlende Dateien, doppelte IDs, ungültige Typen und nicht erlaubte Pfade werden mit Fall ID gemeldet; ein ungültiger Datensatz startet keinen Benchmark.
F02	MUSS	Annotationen erfassen und versionieren. Jeder freigegebene Fall besitzt Referenztext, Hauptkategorie, Split, Quelle und Prüfstatus; Änderungen bleiben nachvollziehbar.
F03	MUSS	Audio und Texte gemeinsam prüfen. Ein gewählter Fall zeigt abspielbares Audio, Referenz und Hypothese; Filter verändern nicht die zugrunde liegenden Daten.
F04	MUSS	Mindestens zwei ASR Konfigurationen vergleichen. Dieselben validierten Fälle und dieselbe Auswertungsvorschrift werden verwendet; Modell und Parameter sind gespeichert.
F05	MUSS	WER, CER und semantisch relevante Slotfehler berechnen. Roh und normalisierte Textauswertung sind getrennt; Handrechenfälle liefern die erwarteten Werte.
F06	MUSS	Fehler nach sprachlichen Kategorien und Schweregrad auswerten. Jeder Kategoriebericht nennt die Zahl der Beispiele und den Nenner seiner Kennzahlen.
F07	MUSS	Laufzeit und Ausfälle erfassen. Jeder Fall besitzt einen Status; Timeouts verschwinden nicht aus der Gesamtauswertung. Modellladezeit und Verarbeitung sind unterscheidbar.
F08	MUSS	Entwicklungs und Testdaten trennen. Zusammengehörige Varianten liegen im selben Split; der Testsplit wird vor endgültiger Modell und Promptbewertung gesperrt.

3 1 Sprachliche Fehler und Datenfehler

Das System muss Datenfehler von Modellfehlern unterscheiden. Eine falsche Referenz wird korrigiert und führt zu einer neuen Datensatzversion; sie wird nicht als Beleg für einen Modellfehler weiterverwendet. Mehrdeutige Audios erhalten den Status unklar und werden vor dem Einfrieren aus dem bewertbaren Kernbestand ersetzt oder separat geführt.

3 2 Erster fachlicher Meilenstein

Das ASR Zwischenprodukt umfasst F01 bis F08, 30 geprüfte Pilotaufnahmen und einen exportierten Bericht. Es ist bereits vor der LLM Integration vorführbar. Die Mindestmenge von 120 Aufnahmen gilt erst für die vollständige Version 1.

4 Anforderungen an LLM und Auswertung

ID	Prio	Anforderung und Akzeptanzbedingung
F09	MUSS	Fiktive Supportdokumentation durchsuchen. Jede verwendete Passage besitzt eine stabile Quelle; erwartete Belege sind im Testfall hinterlegt.
F10	MUSS	Französische Antworten aus Frage und Dokumentauszügen erzeugen. Modell, Promptversion, Quellen und Originalantwort werden pro Fall gespeichert.
F11	MUSS	Antworten nach festgelegter Rubrik bewerten. Inhaltliche Richtigkeit, Belegbarkeit und angemessenes Rückfragen oder Ablehnen sind prüfbar; nicht bewertete Antworten gelten nicht als bestanden.
F12	MUSS	Mindestens zwei Promptvarianten auf derselben Testsuite vergleichen. Dokumentbestand, Modell und Ausgabegrenzen bleiben für diesen Vergleich gleich.
F13	MUSS	Gepaarte End to End Auswertung ermöglichen. Für dieselbe Anfrage werden Referenztext und ASR Text mit derselben LLM Konfiguration geprüft; Folgen für Retrieval und Antwort sind sichtbar.
F14	MUSS	Regressionsprüfung durchführen. Kompatible Läufe werden anhand versionierter Schwellen verglichen; inkompatible oder unvollständige Läufe erhalten kein grünes Gesamtergebnis.
F15	MUSS	Dashboard bereitstellen. Filter für Lauf, Split, Kategorie und Status sowie Fallvergleich und Audiozugriff funktionieren auf gespeicherten Ergebnissen.
F16	MUSS	Maschinenlesbare Ergebnisse und lesbaren Bericht exportieren. Kennzahlen, Nenner, Ausfälle, Konfiguration und Grenzen sind ohne Dashboard interpretierbar.
F17	MUSS	Reproduzierbare Wiederaufnahme ermöglichen. Bereits erfolgreich bearbeitete Fälle werden nur bei unveränderten Eingaben wiederverwendet; abgeschlossene Läufe bleiben unverändert.
F18	SOLL	Zusätzliche spontane Spracheingabe unterstützen. Ein Nutzer kann eine neue Aufnahme prüfen; sie gelangt nicht automatisch in den gesperrten Testbestand.

Ein LLM als Bewerter ist eine KANN Erweiterung. Ein solches Urteil muss mit menschlichen Bewertungen verglichen werden und darf die Abnahme nicht allein entscheiden. Ein simuliertes Modell ist ausschließlich für Softwaretests und die Offline Demo zulässig; reale Benchmarks müssen als solche nachgewiesen sein.

5 Daten und Qualitätsanforderungen

ID	Verbindliche Datenanforderung
D01	120 freigegebene französische Aufnahmen im Kernbestand; sechs Hauptkategorien mit je 20 Fällen. Davon je Kategorie 15 Entwicklung und 5 Test; insgesamt 90 und 30.
D02	60 LLM Fälle in sechs Verhaltensgruppen mit je 10 Fällen; pro Gruppe 5 Entwicklung und 5 Test. Die 30 Testfälle sind mit den 30 ASR Testaufnahmen verknüpft.
D03	12 bis 20 selbst verfasste französische Supportdokumente mit stabilen IDs, Versionen und expliziten Sollbelegen. Keine realen Passwörter, Kunden oder Patientendaten.
D04	Herkunft und Nutzbarkeit von Audio, Text, Modellen und Zusatzdaten sind dokumentiert. Veröffentlichung erfolgt nur für ausdrücklich dafür freigegebene Bestandteile.
D05	Datensatzversion, Split, Prüfer, Prüftermin, Kategorien und Referenzänderungen sind nachvollziehbar. Sollantworten und Bewertungslabels sind für Inferenz und Retrieval unzugänglich. Nur im Referenzzweig dient die geprüfte Transkription als Anfrage.

ID	Qualitätsanforderung und Nachweis
N01	Wiederholbarkeit: Aus identischen gespeicherten Vorhersagen und identischer Auswertungskonfiguration entstehen identische Scores bis auf Rundung; Modellinferenz kann variieren.
N02	Integrität: Fehlerhafte Eingaben und Providerfehler führen zu expliziten Statuswerten. Abgeschlossene Runs werden nicht überschrieben.
N03	Geschwindigkeit: Gespeicherte Ergebnisse mit 1000 Fällen sind auf dem dokumentierten Referenzgerät in höchstens 5 Sekunden initial sichtbar; Filter p95 höchstens 2 Sekunden.
N04	Ressourcen: Kernanalyse funktioniert auf CPU ohne GPU. Für lokale Inferenz wird ein Hardwaretest durchgeführt; eine konkrete Modelllaufzeit wird nicht vorab garantiert.
N05	Vertraulichkeit: Standardbetrieb bindet lokal; Geheimnisse sind weder in Git noch im Export. Externe Übertragung ist standardmäßig deaktiviert.
N06	Wartbarkeit: Datenprüfung, Adapter, Metriken und UI sind getrennt. Kritische Grenzfälle besitzen deterministische Tests ohne externe Dienste.
N07	Bedienbarkeit: Ein Nutzer kann anhand des README die gespeicherte Demo starten, einen Zahlenfehler finden und einen Vergleich exportieren.
N08	Nachvollziehbarkeit: Jeder veröffentlichte Score ist auf Fälle, Konfiguration, Versionen und Ausfälle zurückführbar; Einschränkungen sind im Bericht sichtbar.

6 Rahmenbedingungen und Lieferumfang

6 1 Technische und organisatorische Annahmen

Geplant ist eine lokale Entwicklung mit Python auf Pascals Windows Rechner; eine Linux Umgebung kann ergänzend genutzt werden. Zugriff auf einen Cluster oder eine GPU wird nicht vorausgesetzt. Als Planungsprofil dienen 16 GB RAM und 20 GB freier Speicher; die tatsächlich verfügbare Ausstattung wird in Woche 1 geprüft. Bei knapperen Ressourcen werden Modellgröße und Batchgröße angepasst, nicht die Bewertungsregeln.

Die sechs Wochen sind ein Planungsszenario mit etwa 15 bis 20 Stunden pro Woche. Sie sind kein zugesagter Liefertermin. Ausgangspunkt ist eine Umsetzung durch Pascal mit begleitender Lernarbeit. Fehlende Kenntnisse und die Aufnahmequalität werden im Pilot eingeplant.

6 2 Kosten und Betrieb

Der Standardpfad verwendet lokale Verarbeitung und frei verfügbare, vor Nutzung lizenzgeprüfte Komponenten. Für optionale externe Inferenz gilt zunächst ein Ausgabenlimit von 0 EUR. Ein späteres Budget, beispielsweise höchstens 20 EUR insgesamt, bedarf einer bewussten Projektentscheidung. Unbekannte Providerkosten dürfen nicht automatisch als null verbucht werden.

Netzwerkzugriff darf für Installation und Modelldownload erforderlich sein. Nach vorbereiteter Installation muss die gespeicherte Demo ohne Netz und ohne API Schlüssel funktionieren. Ein externer Inferenzdienst ist kein notwendiger Bestandteil der Offline Demo.

6 3 Verbindliche Liefergegenstände

Liefergegenstand	Inhalt
L01 Spezifikation	Dieses Lastenheft und das zugehörige Pflichtenheft mit identischen Anforderungs IDs.
L02 Implementierung	Versionierter Quellcode, Installationsdateien, Konfigurationen und automatisierte Tests.
L03 Datenpaket	Manifest, freigegebene Aufnahmen, Annotation Guide, Data Card und fiktive Wissensbasis.
L04 Ergebnisse	Zwei ASR Konfigurationen, zwei LLM Promptvarianten und ein gepaarter End to End Vergleich auf dem gesperrten Testbestand.
L05 Bericht	Methodik, Metriken, Fehleranalyse, Regressionsergebnisse, Einschränkungen und reproduzierbare Befehle.
L06 Demonstration	Lokales Dashboard mit gespeicherten Beispielen und ein Ablauf für eine fünfminütige Vorführung. Eine Videoaufnahme ist optional.

GitHub Veröffentlichung und öffentliches Hosting sind separate spätere Handlungen. Die Spezifikation verlangt ein veröffentlichungsfähiges Paket, nicht die automatische Veröffentlichung persönlicher Sprachaufnahmen.

7 Abnahme und Erfolgskriterien

7 1 Verfahren

Die Abnahme erfolgt anhand der im Pflichtenheft beschriebenen Tests T01 bis T18. Für jeden Test werden Datum, Versionsstand, Ergebnis und Belegpfad protokolliert. Alle MUSS Anforderungen einschließlich D01 bis D05 und N01 bis N08 müssen erfüllt sein. F18 darf mit Begründung offen bleiben. Eine Änderung an einer MUSS Anforderung muss vor der Abnahme dokumentiert werden.

Gate	Bedingung für die Freigabe
G1 Daten und Pilot	30 gültige Pilotaufnahmen, Annotationsregeln und keine offensichtliche Splitvermischung; ASR Zwischenbericht liegt vor.
G2 Vollständige Funktion	120 Audiofälle, 60 LLM Fälle und 12 bis 20 Dokumente sind validiert; sämtliche MUSS Funktionen bestehen ihre Tests.
G3 Evaluation	Echte Modellläufe und vollständige menschliche Bewertungen der festgelegten Testantworten liegen vor; Fehler, Nenner und Konfigurationen sind dokumentiert.
G4 Übergabe	Offline Demo und README funktionieren auf dem Referenzgerät; Bericht und Ergebnisdateien stimmen überein; kein offener kritischer Softwarefehler.

7 2 Fehlerklassen bei der Abnahme

Kritisch sind unter anderem falsche Metriken, versteckte fehlgeschlagene Fälle, Testdatenleckage, Überschreiben abgeschlossener Ergebnisse oder Offenlegung von Geheimnissen. Solche Fehler blockieren die Abnahme. Wesentliche Bedienungsfehler, die ein MUSS Szenario verhindern, blockieren ebenfalls. Kosmetische Mängel ohne Auswirkung auf den Ablauf dürfen mit Termin und Verantwortlichem dokumentiert werden.

7 3 Modellqualität und Aussagegrenzen

Es gibt keinen verpflichtenden absoluten WER oder LLM Qualitätsscore, der vor Messung festgelegt wird. Die erste reale Auswertung liefert die Baseline. Spätere Regressionstoleranzen sind im Pflichtenheft als projektinterne Ausgangswerte definiert und dürfen nur mit Begründung versioniert geändert werden.

Ein Benchmark mit überwiegend einem Sprecher, kontrollierten Aufnahmen und fiktiver Supportdomäne belegt keine allgemeine Eignung für medizinische, industrielle oder alle französischsprachigen Einsatzgebiete. Verbesserungen auf 30 Testfällen sind deskriptiv zu berichten. Ein höherer Score allein ist kein Nachweis statistischer Signifikanz.

7 4 Abnahmeprotokoll

Das Protokoll enthält Release ID, Commit, Datensatz und Wissensbasisversion, verwendete Modelle, Testergebnisse, offene Punkte und die Entscheidung

angenommen oder nicht angenommen. Die Freigabe durch Pascal ist erst bei tatsächlicher Prüfung einzutragen; dieses Dokument enthält keine vorweggenommene Freigabe.

8 Projektplanung und Risiken

Woche	Ergebnis	Aufwand
1	Projektaufbau, Hardwaretest, Richtlinien, 30 Pilotaufnahmen	16 h
2	ASR Adapter, Metriken, 120 Aufnahmen und Split Freeze	18 h
3	ASR Vergleich, Fehleranalyse und erstes Dashboard	16 h
4	Wissensbasis, Retrieval, 60 LLM Fälle und Prompts	18 h
5	Gepaarte Auswertung, menschliche Bewertung und Regression	20 h
6	Tests, Bericht, Reproduktion und Vorführung	16 h
Reserve	Überarbeitung von Daten, Installation und unerwartete Fehler	16 h
Gesamt	Planungsumfang einschließlich Reserve	120 h

Die Reserve liegt innerhalb eines Budgets von maximal 20 Stunden pro Woche. Wird dieses Budget überschritten, verlängert sich der Kalenderplan oder eine versionierte Umfangsänderung wird beschlossen. Ein externer Reviewer ist nicht in den 120 Stunden enthalten.

Risiko	Eintritt und Wirkung	Gegenmaßnahme
R1 Inferenz zu langsam	Mittel / hoch	Früher Hardwarepilot, kleinere Modelle, gespeicherte Demo; keine ungemessenen Echtzeitversprechen.
R2 Unsaubere Referenzen	Hoch / hoch	Zweiter Hördurchgang, klare Regeln und dokumentierte Unklarheiten.
R3 Testdaten beeinflussen Tuning	Mittel / hoch	Gruppiertes Split, eingefrorene Prompts, neuer Testbestand nach wiederholter Anpassung.
R4 Zu wenig Zeit	Hoch / mittel	ASR zuerst; F18 und automatische LLM Bewertung verschieben; Kernfunktionen erhalten.
R5 Subjektive Bewertung	Mittel / hoch	Rubrik mit Beispielen, verblindete Reihenfolge und erneute Bewertung einer Stichprobe.
R6 Modell oder Lizenz ungeeignet	Mittel / mittel	Auswahlentscheidung in Woche 1; austauschbarer Adapter und dokumentierte Ersatzoption.
R7 Kosten oder Dienstausfall	Mittel / mittel	Lokaler Standardpfad, begrenzte Wiederholungen und Abbruch vor Kostenüberschreitung.

9 Änderungen und Begriffe

9 1 Änderungsverfahren

Jede Änderung erhält eine CR ID und beschreibt Anlass, betroffene Anforderungen, Auswirkungen auf Aufwand, Daten, Tests und Vergleichbarkeit. Pascal entscheidet projektintern über Annahme oder Zurückstellung. Nach der Änderung werden Lastenheft, Pflichtenheft und Testmatrix gemeinsam aktualisiert. Ein gelöscht Anforderungskennzeichen wird nicht neu vergeben.

Änderungen an Testdaten, Normalisierung oder Rubrik erzeugen eine neue Evaluationsversion. Ergebnisse unterschiedlicher Versionen dürfen nicht ohne gekennzeichnete Neuberechnung direkt verglichen werden. Änderungen an Code und Dokumenten werden über nachvollziehbare Versionsstände verbunden.

9 2 Vor Umsetzung zu entscheidende Punkte

ID	Entscheidung	Termin und Standard
E01	Referenzgerät und Laufumgebung	Woche 1; tatsächliche CPU, RAM, Betriebssystem und freier Speicher dokumentieren.
E02	ASR und LLM Modelle	Woche 1 nach Hardware und Lizenzprüfung; zwei ASR Konfigurationen und ein LLM für zwei Prompts.
E03	Externe Inferenz und Budget	Vor erster externer Übertragung; Standard deaktiviert und 0 EUR.
E04	Publikationsumfang der Aufnahmen	Vor Veröffentlichung; Standard lokal, keine stillschweigende Freigabe.
E05	Zusätzlicher Reviewer	Vor Bewertung; Standard Selbstbewertung mit offengelegter Einschränkung.

9 3 Glossar

Begriff	Bedeutung
ASR oder STT	Automatische Spracherkennung beziehungsweise Speech to Text.
Referenz und Hypothese	Geprüfter Solltext und vom Modell erzeugter Text.
WER und CER	Fehlerrate bezogen auf Referenzwörter beziehungsweise Referenzzeichen.
LLM	Sprachmodell zur Generierung von Textantworten.
Retrieval und RAG	Suche nach passenden Dokumentstellen und Nutzung dieser Stellen bei der Antwortgenerierung.
Baseline und Regression	Festgelegter Vergleichslauf und Verschlechterung gegenüber diesem Lauf.

Begriff	Bedeutung
Slot	Für die Aufgabe wichtige Information, etwa Uhrzeit, Ticketnummer oder Negation.
Freeze und Holdout	Eingefrorener Versionsstand und für die finale Prüfung zurückgehaltene Fälle.

Grundlagen: Projektbeschreibung im Gespräch vom 18. September 2026 sowie die von Pascal bereitgestellte Stellenanzeige mit Veröffentlichungsdatum 25. August 2026. Die Anzeige dient der fachlichen Orientierung und ist keine Zusage des Unternehmens.