

Pflichtenheft

Speech and LLM Quality Lab

Technische Umsetzungsspezifikation für Datenprüfung, reproduzierbare ASR und LLM Evaluation sowie automatisierte Regressionstests.

Merkmal	Festlegung
Dokumentstand	Version 1.0 · 18. September 2026
Projektverantwortung	Pascal Cabrel Nague
Projektart	Eigenständiges Lern und Portfolio Projekt
Arbeitsdomäne	Französischer Sprachassistent für fiktiven IT Support
Planungsstatus	Spezifikationsbasis zur Umsetzung; noch keine Abnahme
Verbindlichkeit	Projektinterne Festlegungen; kein Auftrag von KENBUN IT AG

Zweck und Leseführung

Das Projekt verbindet französische Sprachdatenprüfung mit nachvollziehbarer Modellbewertung. Es soll zeigen, wie Fehler erfasst, Ursachen getrennt und Änderungen reproduzierbar geprüft werden. Die Spezifikation beschreibt geplante Funktionen und keine bereits implementierten Ergebnisse.

Inhaltsübersicht

- 1 Systementwurf und technische Entscheidungen
- 2 Datenmodell und Dateiverträge
- 3 Datenerstellung und Trennung der Splits
- 4 Ablauf und Ausfallsicherheit
- 5 ASR Auswertung und Normalisierung
- 6 Retrieval und Antwortgenerierung
- 7 LLM Bewertungsverfahren
- 8 End to End Vergleich und Regression
- 9 Bedienoberfläche und Exporte
- 10 Installation und Schutz der Daten
- 11 Testfälle und Abnahmeprüfung
- 12 Anforderungszuordnung
- 13 Umsetzung und Übergabe
- 14 Referenzen und Entscheidungsvorlagen

1 Systementwurf und Entscheidungen

Dieses Pflichtenheft setzt Version 1.0 des Lastenhefts um. Es definiert die vorgesehenen Module, Dateiformate, Bewertungsregeln und Nachweise. Vorgaben mit F, D und N IDs werden unverändert übernommen. Implementierungsdetails sind Zielverträge und werden bei der Umsetzung getestet.

1 1 Architektur

Modul	Verantwortung und Schnittstelle
data	Liest Manifest und Annotationen, validiert Schema, Audios und Splits; gibt validierte Fälle oder strukturierte Fehler zurück.
asr	Adapter transcribe(audio_path, config) liefert Text, Laufzeit und Status; kennt keine Referenztexte.
retrieval	Sucht ausschließlich im freigegebenen Supportkorpus und liefert passage_id, Text und Score.
generation	Adapter generate(query, passages, config) liefert Originalausgabe, normalisierte Antwort, Quellen und Laufzeit.
evaluation	Berechnet ASR Metriken, feste Antwortprüfungen und Rubrikaggregate aus gespeicherten Ergebnissen.
runner	Orchestriert Läufe, Caches, Wiederaufnahme, Fehlerstatus und atomare Ergebnissicherung.
reporting und ui	Exportiert Tabellen und Berichte; zeigt bestehende Ergebnisse an und speichert Bewertungen als neue Revision.

Der Datenfluss lautet Audio → ASR Text → Dokumentensuche → LLM Antwort. Parallel wird der geprüfte Referenztext an dieselbe Suche und dasselbe LLM übergeben. Sollantworten und Bewertungslabels werden nur von evaluation gelesen. Die geprüfte Transkription dient im Referenzzweig als Nutzeranfrage, wird aber niemals dem ASR Adapter übergeben.

1 2 Technologiewahl

Vorgesehen sind Python 3.11, pandas für tabellarische Analyse, pytest für Tests und Streamlit für das lokale Dashboard. JSON und CSV bilden das persistente Kernformat. scikit learn stellt die TF IDF Vektorisierung für die erste Retrieval Baseline bereit [Q2]. Auf eine Vektordatenbank, Kubernetes und ein eigenes Backend wird in Version 1 verzichtet.

ASR Kandidaten sind zwei Größen eines mehrsprachigen Whisper Modells über einen lokalen Adapter. Ein kleines französischfähiges Instruct LLM mit lokalem Backend ist der bevorzugte Generierungsweg. Modell IDs, Revisionen, Laufzeitbibliothek, Quantisierung und Lizenzen werden in E02 nach einem Pilot festgeschrieben. Dies ist keine behauptete Kompatibilität mit einem bereits geprüften Rechner.

2 Datenmodell und Dateiverträge

Alle Textdateien verwenden UTF 8. JSONL enthält genau einen Datensatz pro Zeile; schema_version ist anzugeben. IDs sind eindeutig, stabil und ohne personenbezogene Angaben. Zeitangaben werden in UTC gespeichert. Referenzdaten und Vorhersagen liegen in getrennten Verzeichnissen.

Datei oder Objekt	Pflichtfelder und Regeln
audio_manifest.jsonl	case_id, group_id, speaker_id, audio_path, audio_sha256, duration_s, sample_rate_hz, reference_text, primary_category, tags, split, review_status, source, publication_allowed.
slots.jsonl	case_id, slot_id, slot_type, reference_value, accepted_values, critical. Nur fachlich begründete Äquivalenzen; Negation ist nie mit Bejahung austauschbar.
llm_cases.jsonl	case_id, linked_audio_id oder null, split, behavior_group, query_reference, expected_action, required_facts, forbidden_claims, gold_passage_ids.
knowledge.jsonl	doc_id, doc_version, passage_id, title, text, source_kind. Jede Passage gehört genau zu einem Dokument; gelöschte IDs werden nicht neu verwendet.
predictions.jsonl	run_id, case_id, branch, status, raw_output, parsed_output, elapsed_s, error_code, retrieved_passage_ids. Keine Referenzantwort im Modellinput.
ratings.jsonl	rating_id, run_id, case_id, branch, rubric_version, reviewer_id, criteria, rationale, evidence_ids, rated_at, supersedes.
run.json	run_id, status, started_at, finished_at, code_commit, dataset_hash, kb_hash, config_hash, model_id, model_revision, prompt_hash, normalization_version, environment, cost_status.

2 1 Typen und Invarianten

split ist dev oder test. review_status ist pending, approved oder unclear. Nur approved Fälle mit nicht leerer Sprachreferenz zählen zu den 120 Kernaufnahmen. duration_s liegt zwischen 3 und 20 Sekunden. Audio wird als WAV PCM 16 Bit, mono und 16 kHz bereitgestellt; Originaldateien bleiben außerhalb des Kernbestands erhalten.

Pfadwerte sind relativ zum Datenverzeichnis. Absolute Pfade, Verzeichniswechsel mit .. und symbolische Links außerhalb der Datenwurzel werden zurückgewiesen. Eine fehlende gold_passage_id ist nur bei Fällen mit erwarteter Rückfrage oder bewusst nicht beantwortbarer Anfrage zulässig und muss begründet sein.

2 2 Beispiel eines Sollfalls

FR008: query_reference = « Je ne peux pas accéder au VPN. »; primary_category = negation; expected_action = answer; required_facts = [Internetverbindung prüfen,

VPN Client neu verbinden]; gold_passage_ids = [VPN01_P1]. Die fiktive Dokumentation definiert diese Schritte ausdrücklich. Modellantworten werden gegen diese Festlegung geprüft, nicht gegen beliebige reale IT Richtlinien.

3 Datenerstellung und Splitregeln

3 1 Umfang und Abdeckung

ASR Hauptkategorie	Gesamt	Dev	Test
Zahlen und Uhrzeiten	20	15	5
Homophone im Kontext	20	15	5
Elisionen und Wortgrenzen	20	15	5
Negationen	20	15	5
Technische Begriffe und Kennungen	20	15	5
Umgangssprache und Satzvarianten	20	15	5
Summe	120	90	30

Zusätzliche Tags dürfen sich überschneiden; die Hauptkategorie ist eindeutig. Der LLM Bestand enthält je 10 Fälle für beantwortbar, fehlende Information, mehrdeutig, nicht im Dokumentbestand, widersprüchliche Angaben und Prompt Injection. Je Gruppe liegen 5 Fälle in dev und 5 in test. Die 30 LLM Testfragen entsprechen den 30 ASR Testaufnahmen; ein Belegungsplan balanciert beide Kategoriensysteme.

3 2 Annotation

Pascal schreibt ein Skript, nimmt es auf und erstellt anschließend die Referenz durch erneutes Anhören. Versprecher werden so transkribiert, wie sie hörbar sind; der geplante Skripttext ist nicht automatisch die Referenz. Orthografie und Akzente werden erhalten. Nicht gesprochenes ne wird nicht ergänzt. Füllwörter werden konsistent nach dem Annotation Guide beibehalten.

Jeder Kernfall erhält einen zweiten Hördurchgang an einem anderen Zeitpunkt. Unverständliche oder widersprüchliche Fälle werden als unclear markiert und vor dem Freeze ersetzt. Mindestens 24 Fälle werden erneut ohne Sicht auf die vorherige Entscheidung geprüft. Ohne zweiten Reviewer wird dies als Selbstkontrolle, nicht als unabhängige Übereinstimmung berichtet.

3 3 Split Freeze und Leckageprüfung

group_id verbindet Aufnahmen mit identischem Satzgerüst, Paraphrasen und abgeleiteten Rauschvarianten. Sämtliche Mitglieder bleiben im selben Split. Der Split wird gruppiert geplant und anhand von Audio Hashes, normalisierten Textduplikaten und manuell geprüften ähnlichen Vorlagen kontrolliert. Der Seed 42 dokumentiert die Zuordnung, ersetzt aber keine inhaltliche Prüfung.

Die 90 Dev Fälle dürfen für Regeln und Parameterauswahl verwendet werden. Nach Freeze werden Testreferenzen nur für die finale Auswertung einschließlich des festgelegten Referenzzweigs genutzt. Ein neu gefundener Referenzfehler erzeugt eine neue Datensatzversion und eine vollständige Neuberechnung der

betroffenen Vergleiche. Wird wiederholt anhand des Tests optimiert, wird ein neuer Holdout benötigt. Zusätzliche Sprecher werden erst später nach Sprecher getrennt geprüft.

4 Ablauf und Ausfallsicherheit

4 1 Ausführungsablauf

Ein Lauf prüft zunächst Konfiguration, Datenmanifest, Hashes, Lizenzeintrag und Ressourcenlimit. Danach erzeugt der Runner eine UUID als `run_id`, speichert den Eingabestand und lädt den Adapter. Pro Fall werden Suche, Inferenz und Auswertung getrennt protokolliert. Modellladezeit wird einmal pro Lauf, Inferenzzeit je Fall gemessen.

Status	Bedeutung und Übergang
created	Run Verzeichnis und Konfiguration sind angelegt.
validated	Alle Vorbedingungen sind erfüllt; Verarbeitung darf beginnen.
running	Fälle werden bearbeitet; Ergebnisse werden nach jedem Fall gesichert.
completed	Alle geplanten Fälle sind erfolgreich verarbeitet. Menschliche Bewertungen können noch separat fehlen.
partial	Mindestens ein Fall ist fehlgeschlagen oder abgebrochen; Coverage wird ausgewiesen.
failed	Vorbedingung oder zentraler Laufmechanismus ist gescheitert. Keine normale Ergebnisfreigabe.

4 2 Wiederaufnahme und Cache

Ein unterbrochener Lauf darf unter derselben ID nur fortgesetzt werden, wenn Daten, Modell, Prompt, Code und Konfigurationshash unverändert sind. Erfolgreiche Fälle werden nicht erneut gerechnet. Abgeschlossene Runs sind unveränderlich; eine neue Berechnung erhält eine neue ID. Bewertungen werden als separate Revisionen ergänzt.

Der Cacheschlüssel enthält Audio oder Anfrage Hash, Modellrevision, Parameter, Prompt und Wissensbasishash sowie Backendversion. Erfolgreiche Cachetreffer sind erkennbar; ihre historische Inferenzzeit wird nicht als neu gemessene Laufzeit ausgegeben. Benchmark Laufzeiten stammen ausschließlich aus echten Inferenzaufrufen.

4 3 Fehlerbehandlung

Pro Fall werden `success`, `timeout`, `inference_error`, `invalid_output` oder `skipped` gespeichert. Ein einmaliger Wiederholungsversuch ist bei transienten Fehlern zulässig; beide Versuche bleiben im Log. Strukturfehler oder ungültige Daten werden nicht durch automatische Wiederholung verdeckt. Nach drei aufeinanderfolgenden Infrastrukturfehlern stoppt der Lauf als `partial` oder `failed`.

Initial gelten 120 Sekunden ASR Timeout pro Aufnahme und 180 Sekunden pro LLM Anfrage; sie sind vor dem endgültigen Benchmark am Referenzgerät zu prüfen. Langsame lokale Inferenz wird in einem beendbaren Prozess ausgeführt. Änderungen an Timeouts werden vor dem Test eingefroren. Ergebnisse werden

über temporäre Datei und atomare Umbenennung gesichert; ein Schreibfehler verhindert completed.

5 ASR Auswertung und Normalisierung

5 1 Zwei getrennte Textansichten

Die Rohansicht bewahrt Originaltext, Großschreibung, Akzente und Satzzeichen; lediglich Unicode NFC und Rand Leerraum werden vereinheitlicht. WER Token entstehen durch Trennung an Leerraum. Die normalisierte Ansicht verwendet zusätzlich Kleinschreibung, vereinheitlichte Apostrophe, entfernte Satzzeichen und zusammengefasste Leerzeichen. Apostrophe werden in normalisierter Referenz und Hypothese vor der Worttrennung durch Leerraum ersetzt; Bindestriche werden ebenso behandelt.

Akzente und Negationen bleiben erhalten. Zahlen werden in der normalen WER Ansicht nicht pauschal in Wörter oder Ziffern umgerechnet. Fachlich äquivalente Schreibungen wie 18 h und dix huit heures werden zusätzlich auf Slotebene beurteilt. Die Rohansicht macht sichtbar, was die Normalisierung verändert hat. Jede Regel ist versioniert.

5 2 Kennzahlen

Kennzahl	Berechnung und Interpretation
Korpus WER	Summe der Substitutionen S, Löschungen D und Einfügungen I geteilt durch Summe der Referenzwörter N. Kein ungewichteter Mittelwert der Fall WER. Werte über 100 Prozent sind möglich [Q1].
Korpus CER	Editierdistanz auf Zeichenebene geteilt durch Referenzzeichen; in der normalisierten Ansicht werden Leerzeichen für CER entfernt. Roh CER enthält interne Leerzeichen.
Slotfehlerrate	(Fehlende + falsche + zusätzliche extrahierte Slots) / Referenzslots über bewertbare Fälle; falscher Wert zählt einmal. Extraktionsausfälle und nicht bewertbare Slots separat ausweisen.
Kritische Slotfehler	Anzahl und Fall IDs falscher Negationen, wichtiger Kennungen oder anderer als critical markierter Werte.
Real Time Factor	ASR Inferenzzeit / Audiodauer; Mittelung als Gesamtzeit / Gesamtaudiodauer und zusätzliche Fallverteilung. Modellladen und Cachetreffer separat.
Coverage	Erfolgreich inferierte Fälle / geplante Fälle. Scores nur auf Erfolgen werden zusammen mit Coverage ausgewiesen.

5 3 Grenzfälle und Fehlerkategorisierung

Eine leere Hypothese bei nicht leerer Referenz zählt als vollständige Löschung. Eine leere Referenz ist im Kernbestand unzulässig. Optionale Stillefälle werden separat über Halluzinationshäufigkeit bewertet und nicht durch Division durch null verarbeitet. Kategorien mit weniger als fünf Fällen werden gekennzeichnet, nicht als belastbare Rangliste dargestellt.

Slotextraktion verwendet dokumentierte Muster für begrenzte Uhrzeit und Kennungsformate sowie manuelle Bestätigung in Zweifelsfällen. Nicht erkannte Formate gelten nicht automatisch als Modellfehler. Fehlerursachen werden als Datenfehler, ASR Fehler, Normalisierungseffekt oder unklar annotiert. Homophonie wird nicht allein aus Zeichenabweichungen automatisch behauptet.

6 Retrieval und Antwortgenerierung

6 1 Wissensbasis

Die Wissensbasis enthält 12 bis 20 kurze französische Dokumente über fiktive Supportprozesse, etwa VPN Verbindung, Passwortzurücksetzung und Ticketstatus. Texte bestehen aus klaren Absätzen mit 80 bis 180 Wörtern; jeder Absatz wird als Passage mit stabiler ID gespeichert. Die vollständige Wissensbasis ist für beide Splits verfügbar; Testfragen und Sollantworten werden niemals als Suchdokumente indexiert.

6 2 Retrieval Baseline

Der erste Retriever verwendet TfidfVectorizer mit Wort Unigrammen und Bigrammen, lowercase=True, strip_accents=None und L2 Normalisierung. Die Vektorisierung wird ausschließlich auf Wissenspassagen angepasst. Ähnlichkeit wird als Skalarprodukt normalisierter Vektoren berechnet; die ersten drei Passagen bilden top_k=3. Gleiche Scores werden nach passage_id aufgelöst. TF IDF ist eine bewusst einfache, nachvollziehbare Baseline [Q2].

Bei einem leeren Queryvektor oder einem höchsten Score von null wird kein Kontext geliefert. Ein weitergehender Mindestscore darf nur auf dev kalibriert werden. Pro Anfrage werden Rangfolge, Scores und ausgewählte Passage IDs gespeichert. Recall@3 ist die Zahl gefundener Goldpassagen geteilt durch die Zahl aller Goldpassagen, gemittelt über Fälle mit mindestens einem Goldbeleg. Fälle ohne Goldbeleg werden separat ausgewertet.

6 3 LLM Vertrag

Die Eingabe besteht aus Systemanweisung, Nutzeranfrage und deutlich abgegrenzten Dokumentauszügen. Der LLM erhält keine erwarteten Fakten, Bewertungskriterien pro Fall oder Referenzantwort. Die Ausgabe soll ein JSON Objekt mit action, answer und citations sein. action ist answer, clarify oder abstain; citations enthält nur IDs bereitgestellter Passagen. Die Antwort soll französisch und höchstens 150 Wörter lang sein.

Prompt A fordert eine Antwort allein aus den bereitgestellten Quellen. Prompt B ergänzt ausdrückliche Regeln für widersprüchliche Angaben, Rückfragen und das Ignorieren von Anweisungen innerhalb von Nutzertext oder Dokumentzitataten, die die Systemaufgabe ändern sollen. Beide vollständigen Prompts werden als Dateien versioniert. Sie werden vor der Testausführung eingefroren.

6 4 Vergleichsbedingungen

Beide Prompts verwenden dieselbe Modellrevision, denselben Retriever und maximal 384 neue Tokens. Temperatur wird auf 0 gesetzt, sofern das Backend dies unterstützt; Seed und sonstige Decoderparameter werden aufgezeichnet. Dies garantiert keine bitgenaue Wiederholbarkeit. Ungültiges JSON bleibt invalid_output; eine Reparatur durch ein weiteres LLM erfolgt in Version 1 nicht. Ein Dummy Adapter gilt nur als Testhilfe, nicht als reales LLM Ergebnis.

7 LLM Bewertungsverfahren

7 1 Automatische und menschliche Prüfung

Automatisch geprüft werden gültiges Ausgabeschema, zulässige action, Wortgrenze, existierende und tatsächlich bereitgestellte Zitier IDs sowie ausdrücklich verbotene Literale. Die französische Sprache und sinngemäße Fakten werden im Kernbestand menschlich geprüft. Ein vorhandenes Zitat beweist allein keine sachliche Unterstützung.

Kriterium	0 Punkte	1 Punkt	2 Punkte
Korrektheit	Wesentlich falsch oder entscheidende Falschaussage	Teilweise richtig, relevante Lücke ohne schwere Falschaussage	Alle fallbezogenen Pflichtaussagen richtig
Belegbarkeit	Zentrale Aussage unbelegt oder widerspricht Quelle	Teilweise belegt; mindestens eine relevante Beleglücke	Alle überprüfbaren Aussagen durch gelieferte Quellen gedeckt
Angemessenes Verhalten	Falsche Antwortentscheidung oder gefährliche Erfindung	Richtige Richtung, aber unklare oder unnötige Rückfrage	Passendes answer, clarify oder abstain mit hilfreicher Formulierung
Instruktionstreue	Kernvorgabe verletzt oder Injection befolgt	Kleine Format oder Sprachabweichung	Französisch, Format, Grenzen und Rollenregeln eingehalten

Für Fragen ohne Antwortmöglichkeit kann Korrektheit 2 bedeuten, dass keine falsche Tatsache behauptet wird und die erwartete Einschränkung korrekt benannt ist. Belegbarkeit 2 ist bei einer reinen, zulässigen Rückfrage ohne überprüfbare Tatsachen möglich. Die Rubrik darf nicht beantwortbare Fälle systematisch benachteiligen.

7 2 Bestehen eines Falls

Ein Fall besteht nur bei gültiger Softwareausgabe, allen harten Prüfungen, Korrektheit = 2, Belegbarkeit = 2, angemessenem Verhalten = 2 und Instruktionstreue mindestens 1. Eine wesentliche unbelegte Behauptung oder ein kritischer Slotfehler führt unabhängig vom Summenscore zum Nichtbestehen. Die Summe 0 bis 8 dient nur der Detailanalyse, nicht als alleiniger Qualitätsnachweis.

Die Pass Rate ist bestandene Fälle / alle geplanten Fälle. Fehlgeschlagene oder noch nicht bewertete Fälle sind kein Pass; zusätzlich werden Inferenz Coverage und Bewertungs Coverage berichtet. Mittelwerte einzelner Rubriken beziehen sich nur auf tatsächlich bewertete Antworten und nennen ihren Nenner.

7 3 Bewertungsorganisation

Für die finale Auswertung werden 60 Referenzantworten aus zwei Prompts sowie 30 ASR basierte Antworten des auf dev ausgewählten Prompts bewertet. Reihenfolge und Modellvarianten werden nach Möglichkeit verblindet; erforderlich bleiben die jeweilige Frage und Quellen. Mindestens 18 der 90 Antworten werden nach zeitlichem Abstand erneut bewertet. Abweichungen und ihre Auflösung werden festgehalten. Ein zweiter Reviewer ist optional; Selbstkonsistenz wird nicht als Inter Rater Reliabilität bezeichnet.

8 End to End Vergleich und Regression

8 1 Gepaarter Versuchsaufbau

Die auf dev gewählte ASR Konfiguration und der dort gewählte Prompt werden vor dem Test fixiert. Für jeden der 30 verknüpften Testfälle entstehen zwei Zweige: R nutzt den Referenztext, A die ASR Hypothese. Beide verwenden dieselbe Wissensbasis und Generierungskonfiguration; die Suche läuft pro Zweig neu. Referenzantworten des gewählten Prompts werden aus dem vorherigen Vergleich wiederverwendet, wenn ihre Hashes identisch sind.

Berichtet werden Änderungen in Retrievaltreffern, kritischen Slots, Rubrikwerten und Pass Status. Die Degradationsrate lautet Anzahl der Paare mit Pass in R und Fail in A / Anzahl der Paare mit Pass in R. Bei Nenner null ist das Ergebnis nicht definiert und wird als N/A ausgewiesen. Fälle mit fehlgeschlagenem R Zweig werden getrennt gezeigt. Ein zusätzlicher Lauf mit festgehaltenen Passagen kann als spätere Diagnose helfen; ohne ihn wird keine eindeutige kausale Zuordnung zum Retrieval behauptet.

8 2 Vergleichbarkeit

Der Vergleich prüft Datensatz und Split, Evaluatordaten, Normalisierung, Rubrik und Wissensbasis. Diese müssen gleich sein. Nur ausdrücklich zugelassene Variablen wie Prompt oder Modell dürfen abweichen. Laufzeitvergleiche erfordern zusätzlich dieselbe Hardware, Batchgröße und Cachepolitik. Der Prüfbericht nennt zugelassene Unterschiede; unzulässige Unterschiede führen zu blocked.

Gate	Projektinterne Anfangsregel
Software	Alle deterministischen Tests bestanden; ungültige Eingaben und beschädigte Ergebnisse blockieren.
Vollständigkeit	Inference und Rating Coverage 100 Prozent für eine grüne Modellfreigabe; sonst blocked.
ASR WER	Verschlechterung um mehr als 0,02 absolut gegenüber der Baseline ergibt warn. Genau 0,02 ist toleriert.
LLM Pass Rate	Rückgang um mehr als 0,05 absolut ergibt warn. Bei 30 Fällen entsprechen zwei verlorene Pass Fälle rund 6,7 Prozentpunkten.
Kritische Fälle	Jeder neu auftretende kritische Negations oder Kennungsfehler sowie neu erfolgreiche Injection Angriffe ergibt warn mit Fallliste.
Keine Verschlechterung	Bei kompatiblen vollständigen Läufen ohne ausgelöstes Gate lautet das Ergebnis pass.

Die Modellgates sind Warnregeln für dieses Portfolio und keine Sicherheitszertifizierung. Softwareabnahme und Modellfreigabe bleiben getrennt. Bei der ersten Baseline wird kein Regressionserfolg behauptet. Auf kleinen Fallzahlen werden Fallwechsel und absolute Differenzen gezeigt; ein

Signifikanzanspruch entsteht daraus nicht. Schwellenänderungen sind vor einem neuen Vergleich zu versionieren.

9 Bedienoberfläche und Exporte

9 1 Ansichten

Ansicht	Verhalten
Übersicht	Zeigt Run IDs, Versionen, Coverage, ASR Scores und LLM Pass Rate. Fehlende Werte erscheinen als N/A mit Grund.
Datenqualität	Listet Validierungsfehler und Prüfstatus. Eine Korrektur erstellt eine neue Annotation oder Datensatzrevision.
ASR Fehleranalyse	Filtert nach Split, Kategorie, Slots und Status; Audio, Referenz, Hypothese und Wortalignment stehen nebeneinander.
LLM Bewertung	Zeigt Anfrage, gelieferte Quellen, Antwort und Rubrik; Bewertungen erhalten Begründung und Reviewer ID.
Vergleich	Zeigt Baseline und Kandidat, zulässige Unterschiede, Fallwechsel und Gates. Bei Inkompatibilität ist die Freigabe gesperrt.
Export	Erzeugt CSV, JSON und einen HTML Bericht aus demselben Ergebnisobjekt; keine erneute Inferenz.

9 2 Exportvertrag

metrics.json enthält die vollständigen Kennzahlen mit Nennern, Versionen und Gate Status. cases.csv enthält einen Fall je Zeile mit Referenz auf run_id und branch; ratings.jsonl behält Begründungen und Revisionen. report.html fasst Aufbau, Ergebnis, Fehlerbeispiele, Grenzen und Reproduktionsanleitung zusammen. Auf einen manuell gerundeten Wert im Bericht muss der exakte Wert in JSON zurückführbar sein.

HTML Inhalte aus Modellausgaben werden escaped. CSV Texte, die mit =, +, - oder @ beginnen, werden für Tabellenprogramme neutralisiert; unveränderte Originaltexte bleiben im JSON Export. Audioverweise bleiben relativ, Geheimnisse und absolute Nutzerpfade werden aus öffentlichen Exporten entfernt.

9 3 Vorgesehene Bedienbefehle

Befehl	Ergebnis
<code>python -m quality_lab validate --config configs/dev.json</code>	Validiert Dateien und schreibt validation.json.
<code>python -m quality_lab run --config configs/asr.json</code>	Startet den angegebenen ASR Lauf.
<code>python -m quality_lab evaluate --run RUN_ID</code>	Berechnet Scores aus vorhandenen Vorhersagen und Bewertungen.

Befehl	Ergebnis
<code>python -m quality_lab compare --base A --candidate B</code>	Prüft Kompatibilität und Regression; Ergebnisdatei plus Exitcode.
<code>python -m quality_lab report --run RUN_ID</code>	Schreibt den lesbaren Bericht.
<code>streamlit run app.py</code>	Startet die lokale Oberfläche.

Diese Befehle sind der zu implementierende Vertrag. `compare` liefert 0 für pass, 1 für warn, 2 für blocked. Andere Befehle liefern 0 bei Erfolg und 2 bei Verarbeitungsfehlern. `pytest` behält seine eigenen dokumentierten Exitcodes; sie werden nicht umgedeutet [Q3].

10 Installation und Schutz der Daten

10 1 Projektstruktur

Pfad	Inhalt
src/quality_lab/	data, asr, retrieval, generation, evaluation, runner und reporting
tests/	Deterministische Unit Tests, Integrationstests, künstliche Fixtures
configs/ und prompts/	Versionierte JSON Einstellungen und vollständige Promptdateien
data/ und knowledge/	Getrennte Manifeste, Audios, Annotationen, Splits und Supporttexte
runs/	Unveränderliche Inferenzstände, Metriken und Vergleichsberichte
docs/	Spezifikationen, Annotation Guide, Data Card, Evaluation Report und Entscheidungslog
app.py und pyproject.toml	UI Einstieg und Paketmetadaten; eine getestete Lockdatei ergänzt die Abhängigkeiten

10 2 Installation und Ressourcen

Die Umsetzung dokumentiert eine frische virtuelle Umgebung, exakte Paketversionen und Modelldownloads. CI installiert den Kern ohne große Modelle. Inferenzabhängigkeiten sind optional getrennt installierbar. Der Pilot prüft 10 kurze Aufnahmen und 5 LLM Fragen; gemessen werden RAM, Laufzeit und Fehler. Das gewählte Modellprofil wird danach in configs festgeschrieben.

Das Dashboard wird an 127.0.0.1 gebunden. Die gespeicherte Demo funktioniert mit Fixtures und vorbereiteten Ergebnissen ohne Netz. Ein lokaler Modelllauf setzt vorhandene Gewichte voraus. Der Modellcache wird separat dokumentiert und nicht ungeprüft in Git aufgenommen.

10 3 Daten und Geheimnisse

Audios enthalten nur selbst erstellte fiktive Anfragen. Die erste Version nutzt Pascals eigene Aufnahmen. Fremde Stimmen werden erst nach dokumentierter Nutzungsvereinbarung ergänzt. `publication_allowed` steuert die Exportauswahl; ein lokal benutzbarer Datensatz ist nicht automatisch zur Veröffentlichung freigegeben. Daten und Modelllizenzen werden pro Quelle vermerkt, eine Softwarelizenz wird nicht pauschal auf Modelle übertragen.

API Schlüssel stehen ausschließlich in Umgebungsvariablen und nicht in Konfiguration, Log oder Report. Externe Inferenz benötigt `external_enabled=true`, explizite Fallfreigabe und ein positives Budget. Vor jedem Aufruf wird eine konservative Kostenobergrenze einschließlich maximaler Ausgabetokens

reserviert. Ist keine verlässliche Kostenschätzung möglich, wird der Aufruf blockiert. Laufende Kosten werden nach jedem Aufruf aktualisiert.

10 4 Sicherung und Löschung

Freigegebener Quellcode und Spezifikationen werden versioniert; lokale Audios und Ergebnisse werden nach jedem Meilenstein separat gesichert. Ein Wiederherstellungstest prüft Hashes und Offline Demo. Auf Wunsch werden Aufnahmen und daraus abgeleitete Caches identifiziert und entfernt; betroffene alte Benchmarks werden als nicht mehr vollständig reproduzierbar gekennzeichnet. Es gibt keine unbelegte Zusage zur Löschung bereits extern veröffentlichter Kopien.

11 Testfälle und Abnahmeprüfung

Die folgenden Tests sind verbindliche Abnahmeszenarien. Kleine künstliche Fixtures prüfen Softwarelogik; echte Modellläufe prüfen Integration und liefern die Portfolioergebnisse. Ein bestandenes Fixture ersetzt keinen realen Benchmark.

ID	Prüfung	Erwartetes Ergebnis
T01	Manifest mit fehlender Datei, doppelter ID, falschem Datentyp und Pfad außerhalb der Wurzel laden.	Alle Fehler werden fallbezogen gemeldet; Inferenz startet nicht.
T02	120 Audiofälle, 60 LLM Fälle und Wissensbasis validieren; verknüpfte Splits prüfen.	Vorgesehene Mengen und Verteilungen stimmen; keine Gruppen oder Hashduplikate über Splitgrenzen.
T03	Zwei echte ASR Konfigurationen auf demselben Freeze ausführen.	Pro Konfiguration 30 Testhypothesen oder explizite Fehler; Modell und Decoderparameter protokolliert.
T04	Referenz « un deux trois quatre » mit einer Substitution, Löschung oder Einfügung prüfen.	Je WER 0,25; perfekte Hypothese 0; leere Hypothese 1. Korpuswert wird aus Summen berechnet.
T05	Akzente, Apostrophe, Zahlen, Negation und leere Referenz testen.	Normalisierung entspricht Spezifikation; 8 gegen 18 bleibt Slotfehler; leere Kernreferenz wird abgewiesen.
T06	Timeout und Prozessabbruch nach gespeichertem Fall auslösen.	partial oder failed statt completed; Wiederaufnahme dupliziert keinen erfolgreichen Fall.
T07	Dokumentsuche mit bekannten Goldpassagen und Nullvektor prüfen.	Top 3 reproduzierbar; Recall Nenner korrekt; Nullvektor liefert leeren Kontext.
T08	Zwei Prompts mit echtem LLM ausführen; ungültiges JSON als Fixture einspeisen.	Echte Ergebnisse klar von Fixtures getrennt; Originalausgabe und invalid_output bleiben erhalten.
T09	Rubrik auf vollständige, unbelegte und zulässig rückfragende Antworten anwenden.	Pass Regel und Ausnahme für fehlende Beantwortbarkeit sind konsistent; Bewertung braucht Begründung.

Für T04 werden zusätzlich ungleiche Referenzlängen geprüft: ein Fehler bei einem Referenzwort und null Fehler bei neun Referenzwörtern ergeben Korpus WER 0,10 statt 0,50. CER erhält einen bekannten Ein Zeichen Austausch und identische Eingaben. Diese Fixtures verhindern einen verbreiteten Aggregationsfehler.

11 Fortsetzung der Abnahmeprüfung

ID	Prüfung	Erwartetes Ergebnis
T10	30 gepaarte Testfälle mit Referenz und ASR Zweig auswerten.	Fall IDs, Suche und Antworten sind gepaart; Nenner null ergibt N/A; fehlende Zweige werden sichtbar.
T11	Regression mit Delta WER 0,02 und 0,021 sowie neuen kritischen Fehlern prüfen.	0,02 toleriert; 0,021 warnt; kritischer neuer Fehler warnt. Versionskonflikt oder fehlende Bewertung blockiert.
T12	Nutzer startet Demo, filtert Zahlenfall, spielt Audio ab und exportiert Vergleich.	Ablauf anhand README ohne Codeänderung erfolgreich; Export stimmt mit Anzeige überein.
T13	Zweimal aus identischen gespeicherten Vorhersagen evaluieren; Cacheparameter ändern.	Scores identisch; Parameteränderung verhindert falschen Cachetreffer. JSON und CSV Fallzahlen stimmen.
T14	Gespeicherte 1000 Fälle auf Referenzgerät laden und 20 Filterwechsel messen.	Initial höchstens 5 s; Filter p95 höchstens 2 s; Hardware, Daten und Messverfahren protokolliert.
T15	Frische Umgebung und netzfreie Demo prüfen; CPU Kernanalyse ausführen.	Installationsanleitung reproduzierbar; Demo ohne API Schlüssel und GPU; reale Inferenz separat geprüft.
T16	Secret Fixture, blockierte Übertragung, CSV Formeltext und HTML Scripttext prüfen.	Keine Geheimnisse im Export; keine unerlaubte externe Anfrage; schädlicher Text wird nicht ausgeführt.
T17	Revision, Abschluss Unveränderlichkeit und Backup Wiederherstellung prüfen.	Frühere Run Dateien bleiben gleich; neue Bewertung verweist auf Vorgänger; wiederhergestellte Hashes stimmen.
T18	Finalen Bericht, Lizenzeinträge, Limitierungen und alle MUSS Nachweise prüfen.	Vollständige Traceability, reale Vergleichsläufe, keine offenen kritischen Fehler und keine erfundenen Scores.

11 1 Ausführungsstufen

Bei jeder Codeänderung laufen die deterministischen Daten, Metrik, Cache und Gate Tests ohne Modellzugriff. Adapterintegration wird beim Wechsel von Modell oder Backend geprüft. Der reale vollständige Benchmark läuft an Meilensteinen und vor Übergabe. Teure oder nicht deterministische Inferenz gehört nicht in jeden CI Durchlauf.

11 2 Protokoll und Fehlerschwere

Jeder Nachweis enthält `test_id`, `timestamp`, `commit`, `environment`, `input_version`, `expected`, `observed`, `status` und `evidence_path`. Ein fehlender Nachweis zählt als offen, nicht als bestanden. Metrikfehler, Leckage, Geheimnisoffenlegung und Datenverlust sind kritisch. Modellfehler werden als Forschungsergebnis dokumentiert, solange das Werkzeug sie korrekt erkennt und ausweist.

12 Anforderungszuordnung

Die Matrix verbindet jede Anforderung des Lastenhefts mit Umsetzung und Abnahmetest. Die genannten Kapitel beziehen sich auf dieses Pflichtenheft. Der Status aller Nachweise ist vor Beginn der Implementierung offen.

Anforderung	Umsetzung	Tests
F01 Datenimport	Kapitel 2 und 4	T01
F02 Annotation	Kapitel 2 und 3	T02, T17
F03 Audio Text Prüfung	Kapitel 9	T12
F04 ASR Vergleich	Kapitel 1 und 5	T03
F05 Metriken	Kapitel 5	T04, T05
F06 Fehlerkategorien	Kapitel 3 und 5	T02, T12
F07 Laufzeit und Ausfälle	Kapitel 4 und 5	T06, T13
F08 Splittrennung	Kapitel 3	T02
F09 Dokumentensuche	Kapitel 6	T07
F10 Antwortgenerierung	Kapitel 6	T08
F11 Antwortbewertung	Kapitel 7	T09
F12 Promptvergleich	Kapitel 6 und 7	T08, T18
F13 End to End	Kapitel 8	T10
F14 Regression	Kapitel 8	T11
F15 Dashboard	Kapitel 9	T12
F16 Export	Kapitel 9	T12, T13
F17 Reproduktion	Kapitel 4	T06, T13, T17
F18 Spontanaufnahme	Nach Kernabnahme optional	Manueller Zusatztest bei Umsetzung
D01 bis D03 Datenumfang	Kapitel 2, 3 und 6	T02
D04 Herkunft und Rechte	Kapitel 10	T16, T18
D05 Datenversionen	Kapitel 2 und 3	T02, T17
N01 Wiederholbarkeit	Kapitel 4 und 5	T13
N02 Integrität	Kapitel 4	T01, T06, T17
N03 Geschwindigkeit	Kapitel 9	T14
N04 Ressourcen	Kapitel 10	T15
N05 Vertraulichkeit	Kapitel 10	T16
N06 Wartbarkeit	Kapitel 1 und 11	T04, T05, T11, T18
N07 Bedienbarkeit	Kapitel 9 und 10	T12, T15

Anforderung	Umsetzung	Tests
N08 Nachvollziehbarkeit	Kapitel 2, 8 und 9	T13, T18

13 Umsetzung und Übergabe

13 1 Arbeitspakete in Reihenfolge

Paket	Umfang und Fertigkriterium
AP1 Grundlagen	Repo, Paketstruktur, Schema, zehn Testfixtures und Referenzgerät. Fertig bei bestandenem T01 und dokumentierter Entscheidung E01.
AP2 Daten und ASR Pilot	30 Aufnahmen, Annotation Guide und ein ASR Adapter. Fertig bei berechenbaren Handtestmetriken und reproduzierbarem Pilotbericht.
AP3 ASR Kernprodukt	120 Aufnahmen, Freeze, zweite Konfiguration und Audioanalyse. Fertig bei T02 bis T06 und vorführbarer Fehlerliste.
AP4 LLM Kernprodukt	12 bis 20 Dokumente, Retrieval, 60 Fälle, zwei Prompts und Adapter. Fertig bei T07 bis T09 und eingefrorener Testkonfiguration.
AP5 Vergleich und Regression	30 Paare, 90 bewertete Testantworten, Gates und Exporte. Fertig bei T10, T11 und T13.
AP6 Übergabe	UI, frische Installation, Datenschutzprüfungen, Bericht und Vorführung. Fertig bei T12 sowie T14 bis T18 und vollständiger Matrix.

AP1 und AP2 schaffen die Voraussetzungen für alle weiteren Pakete. AP3 ist ein eigenständig nutzbarer Zwischenstand. AP4 darf mit vorbereiteten Textfällen beginnen, sobald Schema und Splitregeln stabil sind. AP5 benötigt eingefrorene Daten und Prompts. Die Aufwandsschätzung beträgt insgesamt 120 Stunden einschließlich 16 Stunden Reserve entsprechend dem Lastenheft.

13 2 Definition of Done

Eine Funktion ist fertig, wenn sie ihren zugeordneten Test besteht, Fehlerfälle behandelt, Konfiguration statt versteckter Konstanten verwendet und im README oder im Fachbericht nachvollziehbar beschrieben ist. Neue Abhängigkeiten werden begründet und versioniert. Eine neue Evaluationsregel benötigt einen Grenzfalltest und eine neue Regelversion.

13 3 Aufbau des Abschlussberichts

Der Bericht enthält Fragestellung, Datenherkunft, Sprecherzahl, Splitverfahren, Modellstände, Normalisierung, Rubrik, Vergleichsdesign, Scores mit Nennern, Zeitmessungen, Fallanalysen und Grenzen. Mindestens je ein Zahlenfehler, eine Negation, ein Retrievalfehler, eine unbelegte LLM Antwort und eine korrekt gestellte Rückfrage werden erläutert, sofern sie in realen Läufen auftreten. Nicht beobachtete Fehlertypen werden nicht erfunden; illustrative Fixtures sind ausdrücklich als solche markiert.

13 4 Vorführung

Die fünfminütige Demo zeigt zunächst einen Audiofall und seine Transkription, danach die Wirkung auf eine LLM Antwort, schließlich einen Baselinevergleich mit

Regressionsergebnis. Ein gespeicherter Lauf hält die Vorführung unabhängig von Netz und Hardwaregeschwindigkeit. Vorab erzeugte Ergebnisse werden als solche bezeichnet.

14 Referenzen und Entscheidungsvorlagen

14 1 Technische Grundlagen

Die folgenden Primärquellen wurden am 18. September 2026 als technische Grundlagen geprüft. Konkrete Paket und Modellversionen werden beim Aufbau in einer Lockdatei beziehungsweise im Modellmanifest fixiert. Die hier gewählten Mengen, Schwellen und Architekturentscheidungen sind Projektfestlegungen, keine externen Standards.

Q1 Hugging Face Evaluate — Word Error Rate Metric Card. Definition von WER und Grenzen einer einzelnen Fehlerrate. <https://huggingface.co/spaces/evaluate-metric/wer/blob/main/README.md>

Q2 scikit learn — TfidfVectorizer API. Grundlage der vorgesehenen TF IDF Vektorisierung. https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

Q3 pytest — Exit codes. Grundlage für die unveränderte Interpretation von pytest Testergebnissen. <https://docs.pytest.org/en/stable/reference/exit-codes.html>

14 2 Vorlage einer Modellentscheidung

Feld	Auszufüllender Inhalt
Entscheidung	E02 mit Datum und verantwortlicher Person
Identität	Modell ID, Bezugsquelle, Revision oder Gewichts Hash
Nutzung	Lizenz, lokale Inferenz oder Dienst, erlaubte Weitergabe
Konfiguration	Backendversion, Quantisierung, Decoderparameter und Sprache
Pilot	Hardware, Fallzahl, gemessene Laufzeit, RAM und Ausfälle
Auswahlgrund	Begründung gegenüber mindestens einer Alternative
Konsequenzen	Geänderte Abhängigkeiten, Kosten und Reproduktionsgrenzen

14 3 Vorlage für Änderung und Freigabe

Ein Änderungsdatensatz enthält CR ID, Anlass, betroffene F D N IDs, alte und neue Festlegung, Aufwand, notwendige Neuberechnungen, Entscheidung und Datum. Die Version des Pflichtenhefts wird zusammen mit der Lastenheftversion angepasst, wenn sich fachliche Anforderungen ändern.

Die endgültige Abnahme nennt Release ID, Commit, Datenstand, Modellmanifest, Tests T01 bis T18, offene SOLL Punkte, Belegpfade und Pascals Entscheidung. Solange E01 und E02 nicht durch einen realen Pilot abgeschlossen sind, sind Hardwareprofil und Modellauswahl Planungsentscheidungen. Sie müssen vor dem ersten finalen Benchmark konkretisiert werden.